Plug-and-Play Language Model을 활용한 한국어 언어모델 독성 제어

장진희[1], 이현민[2], 서대룡[3], 전동현[4], 강인호[5], 나승훈[*6]
전북대학교[1,2,*6], 네이버[3,4,5]
{zhenxi, leehm, nash}@jbnu.ac.kr, {daeryong.seo, donghyeon.jeon, once.ihkang}@navercorp.com

Plug-and-Play Language Model for Controlling Toxicity in Text Generation

Jinhee Jang[1], Hyeon-Min Lee[2], Daeryong Seo[3], Donghyeon Jeon[4], Inho Kang[5], Seung-Hoon Na[*6]
Jeonbuk National University[1,2,*6], NAVER Corporation[3,4,5]

요 약

방대한 데이터셋을 기반으로 언어모델이 급속도로 발전하고 있는 가운데, 언어모델이 생성한 텍스트의 안전성에 대한 연구가 중시되고 있다. 본 연구에서는 Plug-and-Play Language Model(PPLM) 방법을 적용하여 한국어 언어 모델의 생성을 제어하는 시도를 하였다. PPLM의 Attribute 모델은 Discriminator의 역할을 하는 독성 이진 분류기로, 한국어 독성 데이터셋인 K-MHaS로 학습하였다. KoGPT2에 Attribute 모델을 적용하여 생성된 텍스트의 독성이 감소하였는지 확인하였다.

1 서 론

언어 모델은 기계학습을 사용하여 자연어를 이해하고 생성하는 모델이다. 텍스트 생성에는 Transformer의 디코더를 기반으로 한 언어모델이 주로 사용된다. 최근 GPT4, LLaMA 와 같은 거대 언어 모델이 발표되었고, ChatGPT와 같은 생성 모델을 기반으로 한 대화모델이 등장하여 관련 연구가 활발하게 이루어지고 있다.

생성 모델의 성능이 높아지고 있다고 하여 모델이 생성한 문장에 대해 모두 안전성이 보장된 것은 아니다. 현재의 언어 모델은 대량의 웹데이터로 학습되어 글의 맥락을 학습하여 상황에 맞는 문장을 생성할 수 있자만 내포된 뜻의 옳고 그름을 분별한 문장 생성은 아직 더 연구가 필요하다. 특히 대화 모델의 경우, 편향되거나 부적절한 답변은 사용자 경험에 부정적 영향을 끼치기 때문에 생성 모델에 대한 안전성 연구는 현재 시점에서 필수 불가결하다.

본 연구에서는 한국어 언어 모델의 생성 안전성을 개선하기 위해 제어 가능한 자연어 생성 연구 중 하나인 Plug-and-Play Language Model(PPLM)[1]방식을 한국어 언어 모델인 KoGPT2에 적용할 것을 제안한다. PPLM 방식을 사용하면 KoGPT2 모델 자체의 파라미터를 업데이트할 필요가 없으며, 독성 데이터로 학습된 작은 크기의 분류 속성 모델이 GPT의 생성에만 관여하여 문장내 독성 토큰이 생성될 가능성을 감소시킨다. 이는 사전 학습된 언어모델을 적은 리소스로 제어하여 생성 안전성을 개선한다는 것에 이점이 있다.

2 관련 연구

GPT-4 Technical Report[2]에서 안전성을 개선하기 위한 내용이 큰 비중을 차지한 만큼, 언어 모델 성능이 비약적으로 증진됨에 따라, 윤리적 관점에서 언어 모델의 안전성을 분석 및 평가하고, 안전 기준을 제시하는 연구가 많아졌다. [3]에서는 웹상에서 수집한 거대한 데이터가 인터넷 커뮤니티 사용자의 성비, 나이와 국가 등 다양한 요인에 따라 정보의 편향이 존재할 수 밖에 없는 이유를 분석하였다. 모델이 비합리적이고 편견적인 의견을 내뱉을 수 있다는 위험성을 고려하여 모델을 설계하고 데이터를 구축해야함을 피력하였다.

[4] 에서는 자연어 처리 모델의 독성과 편향성이 모델의 성능과 안정성에 미치는 영향을 조사하였다. 실험 결과 학습 데이터와 학습된 모델 모두 독성과 편향성을 가짐을 확인하였고, 평가를 위한 REALTOXICITYPROMPTS 데이터셋을 공개하며 독성을 정량적으로 평가하는 방법을 제시하였다.

텍스트 생성 모델의 독성을 제거하는 해독(Detoxification) 방법론 역시 모델 안전성 개선을 위한 주요한 연구 중 하나이다. [5]에서는 대화 모델의 구조에 챗봇-유저의 대화 데이터셋으로 학습된 독립적인 분류 레이어를 추가하여, 공격적인 발화에 대해 안전한 토픽으로 대응하게끔 설계하였다. 또한 챗봇과 유저의 대화 데이터셋을 사전 학습하여 생성모델을 해독하였다.

본 논문의 실험에서 사용한 PPLM[1]은 앞의 두 논문에서 소개한 해독 방법론과 다르게 작은 크기의 Discriminator가 모델의 디코딩에 관여하여 독성을 제어할 수 있다. 이와 같이 Discriminator와 Generator 모델이 결합한 텍스트 생성에 관련한 다른 연구로는 [6]가 있다. GeDi는 생성된 결과를 판별 모델로 전달하여 생성된 결과의 질을 평가하고, 이를 토대로 생성 모델을 업데이트하여 더 나은 결과물을 생성하도록 한다.

3 PPLM의 문장 생성 제어

Transformer의 디코더는 효율적인 구현을 위해 스탭t의 토큰 생성 당시 사용된 key-value쌍을 과거 행렬(History Matrix)로써 저장하여 다음 스탭$t+1$의 토큰을 생성할때 활용한다. 스탭 t에서 저장된 과거행렬을 $H_t = H_t = [(K_t^{(1)}, V_t^{(1)}), \cdots (K_t^{(l)}, V_t^{(l)})]$라고 했을 때, Transformer 디코더의 반복적인 생성은 (1)과 같이 표현된다.

$$o_{t+1}, H_{t+1} = LM(x_t, H_t) \tag{1}$$

$$\tilde{H}_t = H_t + \Delta H_t \tag{2}$$

PPLM에서 H_t는 제어하고자 하는 속성에 가까워지도록 (2)와 같이 업데이트 된다. 이는 현재 가지고 있는 속성의 정도를 측정하는 Attribute 모델로 인해 도출된 gradient ΔH_t와 H_t가 더해진 값이다. 본 논문에서 Attribute 모델은 1개의 Linear layer로 이루어진 간단한 독성 분류기로 Discriminator의 역할을 한다. 업데이트된 $\tilde{H}_t$ 값을 LM에 다시 입력할 경우, 이전보다 더 원하는 속성에 가까워진 확률 분포를 생성할 수 있는 $\tilde{o}_{t+1}$값이 생성된다. (3)

$$\tilde{o}_{t+1}, \tilde{H}_{t+1} = LM(x_t, \tilde{H}_{t+1}) \tag{3}$$

4 실험

4.1 데이터셋

본 논문의 실험에서 사용한 데이터셋은 다음과 같다.

- A Multi-label Hate Speech Detection Dataset in Korean Online News Comment (K-MHaS) - [7]에서 공개된 K-MHaS는 혐오 표현이 포함된 한국어 뉴스 댓글 데이터셋이다. 각 샘플은 정치성향, 출신, 외모, 연령, 성, 종교 그리고 인종 차별과 혐오 욕설에 대해 다중 레이블로 분류되었다.
- Korean Unsmile Dataset (KUD) - [8]에서 공개된 한국어 혐오 표현 데이터셋이다. 뉴스의 댓글과 인터넷 커뮤니티의 글을 수집하여 다중 레이블로 분류한 것으로 각 샘플은 여성/가족, 남성, 성소수자, 인종/국적, 연령, 지역, 종교, 기타혐오, 악플/욕설과 혐오 표현이 없는 깨끗한 데이터에 대해 분류 되었다.
- Korean HateSpeech Dataset (KHD) - [9]에서 공개된 한국어 연예 뉴스 댓글 혐오 표현 데이터셋이다. 각 샘플은 두가지 조건에 의해 분류 되었다. 첫번째는 샘플이 혐오적, 공격적, 일반적 표현인지 여부이다. 두번째는 성별, 정치, 종교, 외모, 나이, 장애, 인종 등 어떤 혐오 표현인지에 대한 카테고리이다.

모두 다중 레이블로 구성된 데이터셋이기 때문에, 실험 진행상 이진 분류를 위하여 레이블을 수정하였다. 혐오 표현을 포함한 독성 문장(toxic)일 경우 1, 비독성(non-toxic) 문장일 경우 0으로 설정하였다. 이진 레이블로 변경한 데이터셋은 독성 68,842건, 비독성 67,896건, 총 136,738건이다.

4.2 독성 생성 제어를 위한 Attribute 모델 학습

PPLM의 Generator로써 사전 학습된 한국어 언어모델인 KoGPT2[1]를 사용하였다. Discriminator 역할을 하는 Attribute 모델은 Generator와 동일한 모델인 KoGPT2에 Classification Head를 추가하여 학습하였다. 이때 KoGPT2의 파라미터는 업데이트 하지 않고, Classification Head에 해당하는 파라미터만 업데이트 한다. Discriminator 학습에는 K-HMaS의 train 데이터셋 총 78,928건을 사용하였다. 모델 학습시 옵티마이저는 Adam, learning rate 1e-4, batch size 64, epoch 10으로 설정하였다. 학습 결과 K-MHaS test 데이터셋 21,927건에 대해 80.01%의 accuracy를 보였다.

4.3 독성 이진 분류기 학습

Attribute 모델이 적용된 Generator의 성능을 평가하기 위해 Transformer Encoder기반 한국어 사전 학습 모델인 KoELECTRA[2]로 독성 이진 분류기를 미세 조정(fine-tuning)하여 사용한다. 해당 분류기는 구체적으로 ① Generator의 텍스트 생성시 필요한 prefix 데이터 구축과 ② 생성된 텍스트의 독성 비율 파악 및 평가에 활용된다.

독성 이진 분류기 미세 조정에는 K-MHas의 valid 데이터셋 8,774건과 KHD train 데이터셋 7,896건을 합하여 총 16,670건의 데이터를 사용하였다. 옵티마이저는 Adam, learning rate 7e-6, batch size 128, epoch 10으로 설정하였다. 학습 결과 KHD valid dataset 471건에 대해 97.89%의 accuracy를 보였다.

4.4 Prefix가 주어진 문장의 생성

Generator에 입력으로 넣어줄 Prefix 데이터는 K-HMaS test 데이터셋의 독성 문장을 공백 기준 앞 두개의 토큰만 슬라이싱하여 구축한다. 그 후, 독성 이진 분류기로 두개의 토큰에 대해 비독성이라고 분류한 것들만 사용한다. 그 결과 총 4,981건의 Prefix 데이터셋을 구축하였다.

4.5 실험 결과

PPLM의 문장 생성 결과를 비교하기 위해 동일한 Prefix 데이터셋 4,981건에 대해 3개의 출력 결과를 확인하였다. 표 1의 왼쪽 컬럼부터 ① Attribute 모델이 적용되지 않은 Original KoGPT2의 출력, ② Attribute 모델이 비독성 속성의 문장을 생성하게끔 제어한 출력과 ③ 비교 확인을 위해 의도적으로 Attribute 모델이 독성 속성의 문장을 생성하게 제어한 출력을 비교하였다.

표 1: PPLM 문장 생성 결과

속성	Original	Attribute-비독성	**Attribute-비독성**
독성 문장 수량	336	1,577	**298**
독성 문장 비율	0.082	0.388	**0.073**

독성 문장은 같은 Prefix 데이터셋 전체에 대해 Attribute-비독성 모델을 적용한 것이 제일 적게 생성되었다. 독성 문장 비율은 Original 출력에 비해 Attribute-비독성으로 제어한 모델이 0.0009(10%) 감소하였다. 한편, Attribute-독성 모델은 Original 모델과 Attribute-비독성 모델에 비하여 두배가 넘는 독성을 보였다.

1) https://github.com/SKT-AI/KoGPT2

2) https://github.com/monologg/KoELECTRA

Prefix	Original	Attribute-독성	Attribute-비독성
전라도 사람들은	전라도 사람들이 전라도 사람이 전라도 사람이라며 **멸시**한다. 전라도 사람들이 **멸시**	이 같은 말을 많이 하죠. 예전에 박 대통령의 호남에 대한 인사가 이명박이다 이런 것을	그 어느 때보다 춥겠는데요. 아침 출근하실 때 하셔
늙은것들 30년지나면	**다 죽는다**는 말을 하고 다녔는데, 그런 **늙은것**들이 다 죽었다는 것은	죽는다. 그럼, 이놈들은 **똥땡이**가 되냐. **늙은것**들이 뭘 해	늙으면 죽는다는 말을 어떻고 늙은것이 늙은 것은 그

표 2: PPLM 문장 생성 예시

이를 통해 Attribute 모델이 텍스트를 원하는 속성에 가깝게 생성하도록 잘 제어 하고 있음을 확인 할 수 있다.

표 4.5는 모델이 생성한 문장 예시이다. 주어진 Prefix "전라도 사람들은"에 대해 Original 문장은 "멸시"라는 단어가 포함된 독성 문장이 생성되었지만, Attribute-독성 모델은 지역 혐오와 관련 없는 일상적인 문장을 정상적으로 출력하였다. 또한 Attribute-비독성 모델은 주어진 Prefix "늙은것들 30년지나면"에 대해 "죽는다", "똥땡이"라는 단어가 포함된 독성 문장을 출력하였다.

5 결론

본 논문에서는 자연어 생성 모델의 안전성을 개선하기 위하여 PPLM 방식을 사용하여 사전 학습된 한국어 언어 모델의 독성 문장 생성을 제어하는 실험을 하였다. KoGPT2와 함께 학습한 Classification Head를 Attribute 모델로 활용하여 독성 문장 생성 비율이 얼마나 감소하였는지 Original 모델과 비교하였다.

최근 대화 모델의 안전성 개선이 화두가 되는 만큼, Aggressive Prompt의 대답 생성을 제어하는 방법이 필요할 것으로 보인다. 향후 연구에서는 Prefix가 주어진 문장의 생성 뿐만 아니라 Prompt에 대한 안전한 대답이 나올 수 있도록 생성을 제어하는 연구를 진행할 예정이다. 독성 대답을 유도할 수 있는 한국어 Prompt 데이터셋이 구축된다면 보다더 적합한 안전성 평가가 진행될 것이며 이는 한국어 언어모델의 안전 성능을 개선할 수 있는 좋은 평가 방법으로 활용될 수 있을 것이라 기대한다.

참고 문헌

[1] S. Dathathri, A. Madotto, J. Lan, J. Hung, E. Frank, P. Molino, J. Yosinski, and R. Liu, "Plug and play language models: A simple approach to controlled text generation," *arXiv preprint arXiv:1912.02164*, 2019.

[2] OpenAI, "Gpt-4 technical report," 2023.

[3] E. M. Bender, T. Gebru, A. McMillan-Major, and S. Shmitchell, "On the dangers of stochastic parrots: Can language models be too big?," in *Proceedings of the 2021 ACM conference on fairness, accountability, and transparency*, pp. 610–623, 2021.

[4] S. Gehman, S. Gururangan, M. Sap, Y. Choi, and N. A. Smith, "Realtoxicityprompts: Evaluating neural toxic degeneration in language models," *arXiv preprint arXiv:2009.11462*, 2020.

[5] J. Xu, D. Ju, M. Li, Y.-L. Boureau, J. Weston, and E. Dinan, "Bot-adversarial dialogue for safe conversational agents," in *Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, pp. 2950–2968, 2021.

[6] B. Krause, A. D. Gotmare, B. McCann, N. S. Keskar, S. Joty, R. Socher, and N. F. Rajani, "Gedi: Generative discriminator guided sequence generation," 2020.

[7] J. Lee, T. Lim, H. Lee, B. Jo, Y. Kim, H. Yoon, and S. C. Han, "K-mhas: A multi-label hate speech detection dataset in korean online news comment," *arXiv preprint arXiv:2208.10684*, 2022.

[8] T. Kang, E. Kwon, J. Lee, Y. Nam, J. Song, and J. Suh, "Korean online hate speech dataset for multilabel classification: How can social science aid developing better hate speech dataset?," 2022.

[9] J. Moon, W. I. Cho, and J. Lee, "Beep! korean corpus of online news comments for toxic speech detection," *arXiv preprint arXiv:2005.12503*, 2020.