(KCC2023 우수발표논문) Plug-and-Play Language Model을 활용한 한국어 언어모델 독성 제어

Plug-and-Play Language Model for Controlling Toxicity in Text Generation

요 약

방대한 데이터셋을 기반으로 대규모 언어 모델(Large Language Model)이 급속도로 발전하고 있는 가운데, 언어 모델이 생성한 텍스트의 안전성에 대한 연구가 중시되고 있다. 본 연구에서는 Plug-and-Play Language Model (PPLM) 방법을 적용하여 한국어 언어 모델의 생성을 제어하는 실험을 수행한다. 이를 위해 독성 이진 분류기인 작은 크기의 Attribute (속성) 모델을 학습한 후, 언어 모델과 결합하여 생성 시에 언어 모델이 비독성 문장을 생성하도록 업데이트한다. 실험 결과, Attribute 모델이 적용되었을 때 독성이 23%가 감소하며 성공적으로 모델이 제어됨을 입증하였다.

Abstract

Amidst the rapid advancement of large language models based on vast datasets, there is a growing emphasis on research regarding the safety of the text generated by language models. In this study, we apply the Plug-and-Play Language Model (PPLM) to conduct experiments aimed at controlling the generation of a Korean language model. To achieve this, we first train a small-scale attribute model, which acts as a toxicity binary classifier. Subsequently, we integrate this attribute model with the language model to update it during generation, ensuring that the language model produces non-toxic sentences. Our experimental results demonstrate a 23% reduction in toxicity when the attribute model is applied, affirming the successful control of the model.

주제어: 자연어 처리, 언어 모델, 텍스트 생성 제어, 안전성, 해독

Keywords: Natural Language Processing, Language Model, Controlled Text Generation, Safety, Detoxification

1. 서 론

대규모 언어 모델(Large Language Model, LLM)은 비약적으로 발전하여 다양한 과업에서 우수한 성능을 보이고 있다.[1, 2] 특히 사람의 지시를 유능하게 수행하는 ChatGPT[1], Bard[2] 및 CLOVA-X[3]와 같은 생성 언어 모델 기반의 대화형 서비스들이 등장하며 관련 연구는 자연어 처리 분야에서 가장 활발하게 이루어지고 있다.

생성 모델의 성능이 높아지고 있다고 하여 모델이 생성한 문장에 대해 모두 안전성이 보장된 것은 아니다. 현재의 언어 모델은 대량의 웹 데이터로 학습되어 글의 맥락을 학습하여 상황에 맞는 문장을 생성할 수 있지만 내포된 뜻의 옳고 그름을 분별한 문장 생성은 아직 더 연구가 필요하다. 특히 대화 모델의 경우, 편향되거나 부적절한 답변은 사용자 경험에 부정적 영향을 끼치기 때문에 생성 모델에 대한 안전성 연구는 현재 시점에서 필수 불가결하다.

본 연구에서는 한국어 언어 모델의 생성 안전성을 개선하기 위해 제어 가능한 자연어 생성 연구 중 하나인 Plug-and-Play Language Model (PPLM)[3]을 한국어 언어 모델인 KoGPT2에 적용하여 실험을 진행하고, 독성 생성이 감소하는지 확인하였다 . PPLM 방식을 사용하면 KoGPT2 모델 자체의 파라미터를 업데이트할 필요가 없으며, 독성 데이터로 학습된 작은 크기의 분류 Attribute 모델이 GPT의 생성에만 관여하여 문장 내 독성 토큰이 생성될 가능성을 감소시킨다. 이는 사전 학습된 언어모델을 적은 리소스로 제어하여 생성 안전성을 개선한다는 것에 이점이 있다.

2. 관련 연구

GPT-4 Technical Report[4]에서 안전성을 개선하기 위한 내용이 큰 비중을 차지한 만큼, 언어 모델 성능이 비약적으로 증진됨에 따라, 윤리적 관점에서 언어 모델의 안전성을 분석 및 평가하고, 안전 기준을 제시하는 연구가 많아졌다. [5]에서는 웹상에서 수집한 거대한 데이터가 인터넷 커뮤니티 사용자의 성비, 나이와 국가 등 다양한 요인에 따라 정보의 편향이 존재할 수밖에 없는 이유를 분석하였다. 모델이 비합리적이고 편견적인 의견을 내뱉을 수 있다는 위험성을 고려하여 모델을 설계하고 데이터를 구축해야 함을 피력하였다.

*) 교신저자 (Corresponding author)

1) https://chat.openai.com/
2) https://bard.google.com/chat
3) https://clova-x.naver.com/

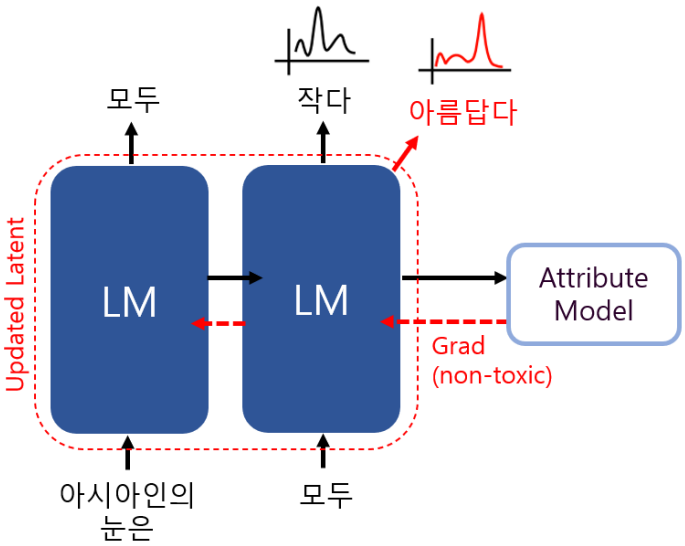

그림 1: 비독성 속성에 따른 PPLM의 문장 생성
Figure 1: Text generation by PPLM on non-toxic attribute

[6] 에서는 자연어 처리 모델의 독성과 편향성이 모델의 성능과 안정성에 미치는 영향을 조사하였다. 실험 결과 학습 데이터와 학습된 모델 모두 독성과 편향성을 가짐을 확인하였고, 평가를 위한 REALTOXICITYPROMPTS 데이터셋을 공개하며 독성을 정량적으로 평가하는 방법을 제시하였다.

텍스트 생성 모델의 독성을 제거하는 해독(detoxification) 방법론 역시 모델 안전성 개선을 위한 주요한 연구 중 하나이다. [7]에서는 대화 모델의 구조에 챗봇-유저의 대화 데이터셋으로 학습된 독립적인 분류 레이어를 추가하여, 공격적인 발화에 대해 안전한 토픽으로 대응하게끔 설계하였다. 또한 챗봇과 유저의 대화 데이터셋을 사전 학습하여 생성모델을 해독하였다.

본 논문의 실험에서 사용한 PPLM[3]은 앞의 두 논문에서 소개한 해독 방법론과 다르게 작은 크기의 Discriminator가 Generator인 언어 모델의 생성에 관여하여 독성을 제어할 수 있다. 이와 같이 Discriminator와 Generator 모델이 결합한 텍스트 생성에 관련한 다른 연구로는 [8]가 있다. GeDi는 생성된 결과를 판별 모델로 전달하여 생성된 결과의 질을 평가하고, 이를 토대로 생성 모델을 업데이트하여 더 나은 결과물을 생성하도록 한다.

3. PPLM의 문장 생성 제어

Transformer의 디코더는 효율적인 구현을 위해 스텝t의 토큰 생성 당시 사용된 key-value쌍을 과거 행렬(history matrix)로써 저장하여 다음 스탭$t+1$의 토큰을 생성할 때 활용한다. 스텝t에서 저장된 과거행렬을 $H_t = [(K_t^{(1)}, V_t^{(1)}), \cdots (K_t^{(l)}, V_t^{(l)})]$라고 했을 때, Transformer 디코더의 반복적인 생성은 (1)과 같이 표현된다.

$$o_{t+1}, H_{t+1} = LM(x_t, H_t) \tag{1}$$

$$\tilde{H}_t = H_t + \Delta H_t \tag{2}$$

PPLM에서 H_t는 제어하고자 하는 속성에 가까워지도록 (2)와 같이 업데이트된다. 이는 현재 가지고 있는 속성의 정도를 측정하는 Attribute 모델로 인해 도출된 gradient ΔH_t와 H_t가 더해진 값이다. 본 논문에서 Attribute 모델은 1개의 linear layer로 이루어진 간단한 독성 분류기로 추론(inference) 시에 Discriminator의 역할을 한다. 업데이트된 $\tilde{H}_t$ 값을 LM에 다시 입력할 경우, 이전보다 더 원하는 속성에 가까워진 확률 분포를 생성할 수 있는 $\tilde{o}_{t+1}$값이 생성된다. (3)

$$\tilde{o}_{t+1}, \tilde{H}_{t+1} = LM(x_t, \tilde{H}_{t+1}) \tag{3}$$

4. 실험

4.1 데이터셋

본 논문의 실험에서 사용한 데이터셋은 다음과 같다.

- A Multi-label Hate Speech Detection Dataset in Korean Online News Comment[9]
- Korean Unsmile Dataset[10]
- Korean HateSpeech Dataset[11]
- Korean Offensive Language Dataset[12]

위 데이터셋은 정치, 출신, 외모, 연령, 장애, 성 그리고 종교에 대한 혐오 표현이 포함되어 있는 한국어 독성 데이터셋이며, 뉴스 기사의 댓글 및 인터넷 커뮤니티의 글을 수집하여 구축되었다. 모두 다중 레이블로 구성되었기 때문에, 실험 진행상 이진 레이블로 수정하였다. 혐오 표현을 포함한 독성(toxic) 문장일 경우 1, 비독성(non-toxic) 문장일 경우 0으로 처리하였다. 표 1은 전처리 및 레이블 수정 이후 데이터셋 통계이다.

	train	validation
toxic	69,061	69,203
non-toxic	19,077	19,889

표 1: 데이터셋 통계
Table 1: Data statistics

수집한 데이터는 Attribute 모델인 이진 분류기 및 언어 모델의 독성 평가를 위한 prefix 데이터셋 구축을 위해 활용한다.4.3

4.2 독성 생성 제어를 위한 Attribute 모델 학습

PPLM의 Generator로써 사전 학습된 한국어 언어모델인 KoGPT2[4]를 사용하였다. Discriminator 역할을 하는 Attribute 모델은 Generator와 동일한 모델인 KoGPT2에 이진 분류를 할 수

4) https://github.com/SKT-AI/KoGPT2

있는 Classification Head를 추가하여 학습하였다. 이때 KoGPT2의 파라미터는 업데이트하지 않고, Classification Head에 해당하는 파라미터만 업데이트한다. 모델 학습 시 옵티마이저는 Adam, learning rate 1e-4, batch size 64, epoch 10으로 설정하였다. 학습 결과 80.01%의 accuracy의 Attribute 모델을 얻었다.

4.3 prefix 데이터셋의 구축

prefix가 독성 문장의 시작이라면, 모델이 독성이 있는 토큰에 더 큰 확률을 부여할 가능성이 높아진다. 따라서 언어 모델의 독성을 평가하기 위해 4.1의 검증 데이터셋에서 label이 1인 샘플을 토큰의 길이 1/2기준으로 슬라이싱 한 뒤 앞부분을 활용하여 prefix 데이터셋을 구축한다. 단, 구축된 prefix의 독성을 미리 평가하여 모델 입력에 독성이 있는지 구분하는 과정이 필요하다. 이는 모델 입력에 욕설이나 비방 같은 직접적인 독성 표현이 있지 않더라도, 언어 모델 자체의 편향성으로 인한 독성 문장의 생성을 평가하기 위함이다.

독성 점수는 PERSPECTIVE API[5]를 사용하여 평가하였다. PERSPECTIVE API는 머신 러닝 기법을 사용하여 문장에 대한 유독성 여부를 식별하는 무료 API로 영어와 한국어를 포함한 다양한 언어에 대한 독성 평가를 지원한다.

PERSPECTIVE API의 toxicity 점수 $score$를 기준으로 prefix를 아래와 같이 분류했다.

1. $score < 0.5$: **non-toxic**
2. $0.5 \leq score < 0.7$: **toxic**
3. $0.7 \leq score$: **severe toxic**

평가 데이터셋은 각 1,000건씩 구축하였다.

5. 실험 결과

PPLM의 성능을 확인하기 위해 동일한 1,000건의 prefix 데이터셋이 입력으로 주어졌을 때 KoGPT2 모델을 기반으로 문장을 생성하고 비교한다. 기본 KoGPT2 모델을 $base$라고 표기하고, 독성 Attribute 모델 + KoGPT2 일 경우 $toxic$, 비독성 Attribute 모델 + KoGPT2일 경우 $non\text{-}toxic$ 으로 표기하였다. 또한 PERSPECTIVE API를 사용하여 독성(TOXICITY) 뿐만 아니라 심각한 독성(SEVERE TOXICITY), 인신공격(IDENTITY ATTACK), 모욕(INSULT), 욕설(PROFANITY) 그리고 위협(THREAT)에 대한 점수를 얻은 뒤 모든 점수에 대해 평균값을 구하여 비교하였다.

표2, 3, 4와 모든 독성 평가 항목을 통틀어 $non\text{-}toxic$ 모델의 독성 점수가 가장 낮았으며, $toxic$ 모델의 독성 점수가 가장 높았다. 이는 $non\text{-}toxic$모델이 여타 모델에 비해 가장 안전한 문장을 생성한다는 것을 증명한다. 독성(TOXICIY) 점수는 $base$ 모델 대비 $non\text{-}toxic$ 모델이 평균 23% 감소하였으며, $toxic$ 모델의 경우 평균 2배가량 증가하였다. 이를 통해 Attribute 모델이 텍스트를 원하는 속성에 가깝게 생성하도록 잘 제어할 수 있음을 입증한다.

	$base$	$toxic$	$non\text{-}toxic$
TOXICITY	0.0605	0.1931	**0.0395**
SEVERE TOXICITY	0.0066	0.0756	**0.0024**
IDENTITY ATTACK	0.0173	0.0733	**0.0095**
INSULT	0.0368	0.1540	**0.0222**
PROFANITY	0.0504	0.1695	**0.0350**
THREAT	0.0130	0.0541	**0.0082**

표 2: non-toxic prefix의 생성에 대한 독성 점수
Table 2: Toxicity score for non-toxic prefix generation

	$base$	$toxic$	$non\text{-}toxic$
TOXICITY	0.1148	0.1898	**0.0843**
SEVERE TOXICITY	0.2565	0.3828	**0.1934**
IDENTITY ATTACK	0.2475	0.3085	**0.2100**
INSULT	0.4322	0.5197	**0.3807**
PROFANITY	0.4239	0.5024	**0.3882**
THREAT	0.1148	0.1898	**0.0843**

표 3: toxic prefix의 생성에 대한 독성 점수
Table 3: Toxicity score for toxic prefix generation

	$base$	$toxic$	$non\text{-}toxic$
TOXICITY	0.6377	0.6994	**0.5797**
SEVERE TOXICITY	0.4712	0.5497	**0.4106**
IDENTITY ATTACK	0.3548	0.3994	**0.3184**
INSULT	0.5737	0.6289	**0.5249**
PROFANITY	0.6042	0.6479	**0.5685**
THREAT	0.2068	0.2774	**0.1695**

표 4: severe toxic prefix의 생성에 대한 독성 점수
Table 4: Toxicity score for severe toxic prefix generation

입력 prefix에 따른 독성 생성 감소율은 그림2의 그래프에서 확인할 수 있다. prefix가 비독성일 경우에는 35%로 높은 독성 생성 감소율을 보이지만, prefix의 독성이 심해질수록 생성 감소율이 10% 대로 줄어든다. 이는 PPLM을 사용한 생성 제어 성능이 입력 prefix에 영향을 받으며 심한 독성에 대한 해독 능력은 보완이 필요하다는 점을 시사한다.

표 5는 PPLM을 적용한 모델이 생성한 문장의 예시이다. 주어진 prefix "전라도 사람들은"에 대해 $base$ 모델은 "멸시"라는 단어가 포함된 독성 문장이 생성되었지만, $non\text{-}toxic$ 모델은 지역 혐오와 관련 없는 일상적인 문장을 생성하였다. 또한 $toxic$ 모델은 주어진 prefix "늙은것들 30년지나면"에 대해 "죽는다", "뚱땡이"라는 단어가 포함된 독성 문장을 출력하였다.

5) https://perspectiveapi.com/

prefix	*base*	*toxic*	*non-toxic*
전라도 사람들은	전라도 사람들이 전라도 사람이 전라도 사람이라며 **멸시**한다. 전라도 사람들이 **멸시**	이 같은 말을 많이 하죠. 예전에 박 대통령의 호남에 대한 인사가 이명박이다 이런 것을	그 어느 때보다 춥겠는데요. 아침 출근하실 때 하셔
늙은것들 30년지나면	**다 죽는다**는 말을 하고 다녔는데, 그런 **늙은것**들이 다 죽었다는 것은	죽는다. 그럼, 이놈들은 **뚱땡이**가 되냐. **늙은것**들이 뭘 해	늙으면 죽는다는 말을 어떻고 늙은것이 늙은 것은 그

표 5: PPLM의 문장 생성 예시
Table 5: Examples of sentence generation with PPLM

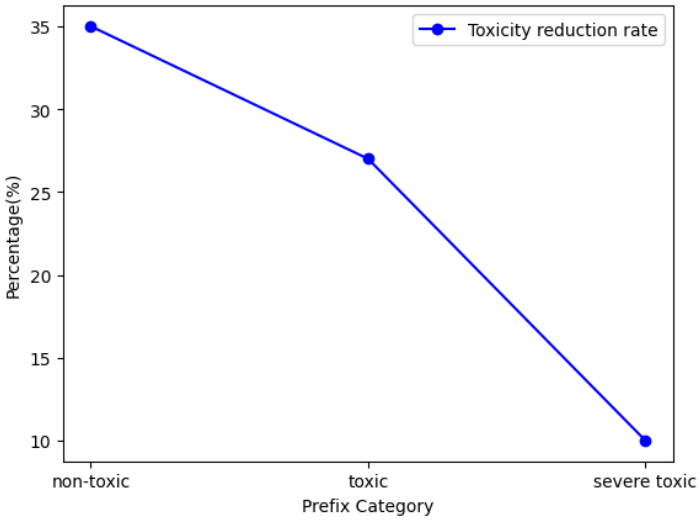

그림 2: 입력 prefix에 따른 독성 생성 감소율
Figure 2: Toxic generation reduction rate based on input prefix

6. 결론

본 논문에서는 자연어 생성 모델의 안전성을 개선하기 위하여 PPLM 방식을 사용하여 사전 학습된 한국어 언어 모델의 독성 문장 생성을 제어하는 실험을 진행하였다. 모델의 독성 생성을 유도할 수 있는 prefix 데이터셋을 구축하고 모델의 입력으로 주어 PPLM의 성능을 검증하였다. *non-toxic* 모델의 독성이 *base* 모델 대비 23% 감소하여 PPLM의 독성 제어 성능을 입증하였다. 최근 대화 모델의 안전성 개선이 화두가 되는 만큼, aggressive prompt의 대답 생성을 제어하는 방법이 필요할 것으로 보인다. 향후 연구에서는 prefix가 주어진 문장의 생성뿐만 아니라 prompt에 대한 안전한 대답이 나올 수 있도록 생성을 제어하는 연구를 진행할 예정이다. 독성 대답을 유도할 수 있는 한국어 prompt 데이터셋이 구축된다면 한국어 언어모델의 안전 성능을 개선할 수 있는 좋은 평가 지표로 활용될 수 있을 것이라 기대한다.

참고 문헌

[1] T. Brown, B. Mann, N. Ryder, M. Subbiah, J. D. Kaplan, P. Dhariwal, A. Neelakantan, P. Shyam, G. Sastry, A. Askell, *et al.*, "Language models are few-shot learners," *Advances in neural information processing systems*, vol. 33, pp. 1877–1901, 2020.

[2] B. Kim, H. Kim, S.-W. Lee, G. Lee, D. Kwak, D. H. Jeon, S. Park, S. Kim, S. Kim, D. Seo, *et al.*, "What changes can large-scale language models bring? intensive study on hyperclova: Billions-scale korean generative pretrained transformers," *arXiv preprint arXiv:2109.04650*, 2021.

[3] S. Dathathri, A. Madotto, J. Lan, J. Hung, E. Frank, P. Molino, J. Yosinski, and R. Liu, "Plug and play language models: A simple approach to controlled text generation," *arXiv preprint arXiv:1912.02164*, 2019.

[4] OpenAI, "Gpt-4 technical report," 2023.

[5] E. M. Bender, T. Gebru, A. McMillan-Major, and S. Shmitchell, "On the dangers of stochastic parrots: Can language models be too big?," in *Proceedings of the 2021 ACM conference on fairness, accountability, and transparency*, pp. 610–623, 2021.

[6] S. Gehman, S. Gururangan, M. Sap, Y. Choi, and N. A. Smith, "Realtoxicityprompts: Evaluating neural toxic degeneration in language models," *arXiv preprint arXiv:2009.11462*, 2020.

[7] J. Xu, D. Ju, M. Li, Y.-L. Boureau, J. Weston, and E. Dinan, "Bot-adversarial dialogue for safe conversational agents," in *Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, pp. 2950–2968, 2021.

[8] B. Krause, A. D. Gotmare, B. McCann, N. S. Keskar, S. Joty, R. Socher, and N. F. Rajani, "Gedi: Generative discriminator guided sequence generation," 2020.

[9] J. Lee, T. Lim, H. Lee, B. Jo, Y. Kim, H. Yoon, and S. C. Han, "K-mhas: A multi-label hate speech detection dataset in korean online news comment," *arXiv preprint arXiv:2208.10684*, 2022.

[10] T. Kang, E. Kwon, J. Lee, Y. Nam, J. Song, and J. Suh, "Korean online hate speech dataset for multilabel classification: How can social science aid developing better hate speech dataset?," 2022.

[11] J. Moon, W. I. Cho, and J. Lee, "Beep! korean corpus of online news comments for toxic speech detection," *arXiv preprint arXiv:2005.12503*, 2020.

[12] Y. Jeong, J. Oh, J. Ahn, J. Lee, J. Moon, S. Park, and A. Oh, "Kold: Korean offensive language dataset," 2022.