다국어 기계번역 모델의 언어 확장

장진희°[1,2], 김영빈[2,3]
NC AI[1], 중앙대학교 AI 대학원[2], 중앙대학교 첨단영상대학원[3]
{jinheejang,ybkim85}@cau.ac.kr

Language Expansion of Multilingual Machine Translation Models

Jinhee Jang°[1,2], Youngbin Kim[2,3]
NC AI[1], Department of Artificial Intelligence, Chung-Ang University[2]
Graduate School of Advanced Imaging Science, Multimedia & Film, Chung-Ang University[3]

요 약

최근 다국어 기계번역 모델은 단일 모델로 수십 개 이상의 언어를 동시에 지원할 수 있는 잠재력을 보여주고 있다. 그러나 새로운 언어를 확장하는 과정에서 기존 언어 성능이 저하되는 치명적 망각(catastrophic forgetting) 문제가 여전히 중요한 도전 과제로 남아 있다. 이러한 성능 저하는 실제 서비스 환경에서 특히 치명적이며, 모델 확장의 의미가 훼손되고 번역 시스템의 신뢰성 또한 저하될 수 있다. 본 연구는 리허설(rehearsal) 기반 학습과 모델 병합(model merging) 기법을 적용하여, 모델 구조를 변경하거나 복잡한 방법론에 의존하지 않고도 기존 언어 성능을 유지하면서 새로운 언어 확장이 가능함을 실험적으로 검증한다. 구체적으로, Qwen2.5 기반 1.5B 번역 모델을 기존 10개 언어에서 16개 언어로 확장하여 평가한 결과, Merged model은 기존 언어 성능을 COMET 기준 99.7% 유지하면서도 신규 언어에서 chrF 기준 7.7–10배, COMET 기준 31–38%의 향상을 달성하였다. 본 연구는 실제 서비스 환경에서 다국어 번역 모델의 확장 가능성과 실용성을 높이는 데 기여한다.

주제어: 기계번역, 연속학습, 언어확장

1. 서론

최근 대규모 다국어 기계번역 모델은 단일 모델로 수십 개 이상의 언어를 동시에 지원할 수 있는 잠재력을 보여주며, 다국어 서비스 환경에서의 활용 가능성을 크게 확장시켰다 [1, 2]. 그러나 새로운 언어를 추가 학습하는 과정에서 기존 언어 성능이 저하되는 치명적 망각(catastrophic forgetting) 문제가 여전히 중요한 도전 과제로 남아 있다 [3, 4]. 이는 특히 실제 서비스 환경에서 심각한 문제를 야기하는데, 사용자가 주로 사용하는 언어의 번역 품질이 떨어질 경우 모델 확장의 의미가 크게 훼손되며 번역 신뢰도 또한 저하된다.

기존 연구들은 주로 모델의 구조를 변경하거나 언어에 맞는 언어 특화 어댑터를 추가하는 방식으로 언어 확장을 시도해 왔다. [5, 6, 7] 그러나 이러한 접근은 실제 서비스 환경에서 모델 구조 변경이 적용과 유지보수에 부담을 주므로 [8], 모델 구조를 최대한 유지한 채 번역 모델을 확장하려는 연구가 여전히 요구된다. 따라서 본 연구는 번역 모델의 구조적 안정성을 유지하면서, 간단한 방식으로 언어 확장을 수행하고 기존 언어 성능을 보존하는 전략을 탐구한다. 구체적으로, (1) 기존 언어 데이터를 일부 포함하는 리허설(rehearsal)[9] 기반 학습, (2) 확장 전 베이스 모델의 파라미터를 부분적으로 유지할 수 있는 모델 병합(model merging)[10] 기법을 적용하여 치명적 망각을 방지한다.

Qwen2.5[1] 기반 1.5B 번역 모델을 기존 10개 언어에서 16개 언어로 확장하는 실험을 수행하였으며, 다양한 리허설 데이터 비율을 검증하여 최적의 설정을 도출하였다. 또한 모델 병합 기법을 적용한 결과, 기존 언어 성능을 COMET 기준 99.7% 수준으로 유지하면서도 신규 언어에서는 chrF 기준 7.7–10배, COMET 기준 31–38%의 개선을 확인하였다.

2. 관련 연구

최근 LLM에서의 언어 확장 연구는 대표적으로 모델 구조적 접근[5, 6]과 연속 학습(continual learning) 기반 접근[7, 11] 등 여러 방식으로 진행되고 있다. 모델 구조적 접근 방법론의 예시로, LayerMoE[5]는 레이어별 언어 표현 유사도를 측정해 필요한 레이어에만 MoE 전문가를 추가했다. 또한 X-ELM[6]는 언어군 단위의 독립적인 전문가 모델을 제안하여 새로운 언어 추가 시 간섭을 최소화하였다.

연속 학습 기반 접근에서는 치명적 망각 문제를 해결하기 위한 다양한 기법이 제안되었다. F-MALLOC[7]은 피드포워드 네트워크를 다수의 메모리 슬롯으로 분해하여 각 언어 혹은 태스크에 대응되는 파라미터를 분리 및 저장하는 방식을 도입하였다. 이를 통해 모델이 새로운 언어를 학습할 때 기존 슬롯의 정보가 손상되지 않도록 보호하였다. 또한 Iterative Continual Learning[11]는 다도메인 번역 환경에서 데이터 순서, 혼합 비율, 학습률 스케줄링을 조정하는 점진적이고 반복적인 학습 전

[1] https://huggingface.co/spaces/Qwen/Qwen2.5

략을 통해 기존 지식을 보존하면서 새로운 도메인과 언어에 안정적으로 적응할 수 있음을 보여주었다.

그러나 기존의 연속 학습 기반 접근은 훈련 절차의 복잡성과 하이퍼파라미터 민감도가 문제로 작용하며, 모델 구조 수정이나 모듈 추가에 의존하는 방법은 망각을 완화하는 데 효과적이지만 구조적 변동으로 인해 실제 서비스 환경에 빠르게 적용하기에는 제약이 따른다.

이에 본 연구는 모델 구조를 크게 변경하지 않고도 언어 확장을 수행하면서 기존 언어 성능을 안정적으로 보존할 수 있는 방법을 탐구한다. 구체적으로, 우리는 (1) 기존 언어 데이터를 일부 포함하는 리허설 기법을 적용하여 학습 과정에서 이전 언어 성능 저하를 방지하고, (2) 학습 전 베이스 모델의 파라미터를 부분적으로 유지할 수 있는 모델 병합 기법을 적용하여 치명적 망각을 최소화하고자 한다.

3. 언어 확장 데이터셋 구축

본 연구에서는 기존 10개 언어를 지원하던 채팅 번역 모델(ChatMT)을 16개 언어로 확장하기 위해 대규모 병렬 데이터셋을 구축하였다. 기존 언어는 한국어, 영어, 스페인어, 독일어, 프랑스어, 일본어, 대만어, 포르투갈어, 중국어, 러시아어이며, 새롭게 아랍어, 베트남어, 인도네시아어, 말레이어, 타갈로그어, 태국어의 6개 언어를 추가하였다. 특히 본 연구는 한국어와 영어 중심의 번역 모델 확장을 목표로 하였기에, 두 언어가 소스(source) 또는 타깃(target)으로 포함된 병렬 데이터만을 구축하였다.

데이터셋 구축 과정은 (1) 한국어 · 영어 원천 데이터 수집, (2) 병렬 데이터 생성, (3) 다단계 필터링, (4) 샘플 검증의 절차를 거쳤다. 먼저, AI허브 및 자사 게임 채팅 로그 등 다양한 도메인에서 한국어와 영어 원천 데이터를 수집하여 모델이 여러 장르와 맥락을 학습할 수 있도록 하였다. 이후 gpt-4o-mini[2]를 활용하여 해당 원천 데이터를 신규 6개 언어로 번역함으로써 병렬 데이터를 생성하였다.

또한 품질 확보를 위해 다단계 필터링을 적용하였다. 규칙 기반 필터링을 통해 기호 불일치와 언어 혼합 사례를 제거하였으며, LabES[3]와 같은 다국어 임베딩 모델을 활용해 소스-타깃 간 의미적 유사도를 계산하였다. 이 과정에서 유사도가 0.98 이상 또는 0.8 이하인 샘플은 비문이나 노이즈에 해당할 가능성이 높다고 판단하여 제외하였다.

마지막으로, 구축된 데이터셋의 품질을 검증하기 위해 언어쌍별로 20건씩 총 240건의 샘플을 직접 검토하였다. 그 결과 약 200만 건(언어쌍별 8-9만 건 수준)의 확장 언어 병렬 데이터셋을 최종 확보하였다.

[2] https://platform.openai.com/docs/models/gpt-4.1-mini

[3] https://huggingface.co/sentence-transformers/LaBSE

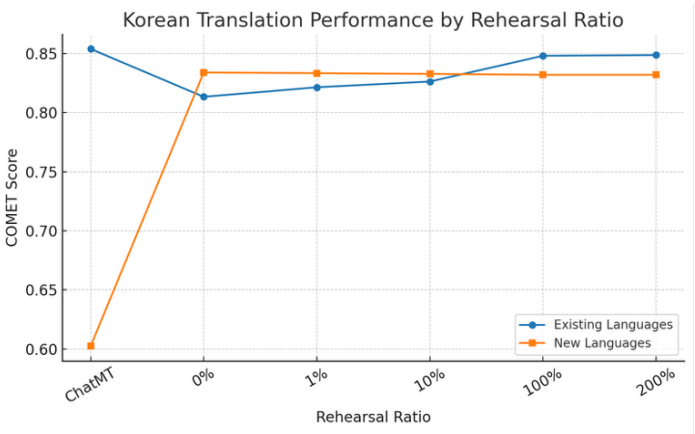

그림 1. 리허설 데이터 비율에 따른 한국어 번역 성능

4. 방법론

4.1 모델 학습

본 연구에서는 신규 언어 확장 과정에서 기존 언어의 성능 저하를 완화하기 위해 연속 학습 기법의 하나인 리허설[9] 방식을 적용하였다. 리허설은 기존 학습 데이터 집합 D와 신규 학습 데이터 집합 M을 결합하여 $\mathcal{D}_{\text{rehearsal}}$을 구성한 뒤 학습하는 방식으로, 다음과 같이 정의된다.

$$\mathcal{D}_{\text{rehearsal}} = \mathcal{D} \cup \mathcal{M} \tag{1}$$

$$\mathcal{L}(\theta) = \frac{1}{|\mathcal{D}| + |\mathcal{M}|} \sum_{(x,y)\in\mathcal{D}_{\text{rehearsal}}} \ell\big(f_\theta(x), y\big) \tag{2}$$

리허설 데이터 샘플링 기존 데이터와 신규 데이터를 결합할 때 특정 언어쌍에 편향되지 않도록, 모든 언어쌍이 동일한 비율을 갖도록 샘플링하였다. 이를 통해 리허설 과정에서 언어 간 균형을 유지하도록 하였다.

리허설 데이터 비율 리허설 데이터의 비율은 전체 학습 데이터에서 신규 데이터 M에 대한 기존 데이터 D의 비율로 정의한다. 본 연구에서는 0%에서 200%까지 다양한 비율을 설정하여 실험을 수행하였다. 특히, 그림 1에서 나타난 바와 같이 COMET 점수를 기준으로 한국어 번역 성능을 비교한 결과, 일정 수준 이상의 비율에서 기존 언어 성능(Existing languages)을 최대한 보존하면서 신규 언어(New languages) 성능 모두 안정적으로 유지되는 것을 확인하였다. 이에 따라 최종 학습에서는 신규 데이터에 대해 100% 및 200% 비율의 리허설 데이터를 각각 사용하여 비교하고자 하였다.

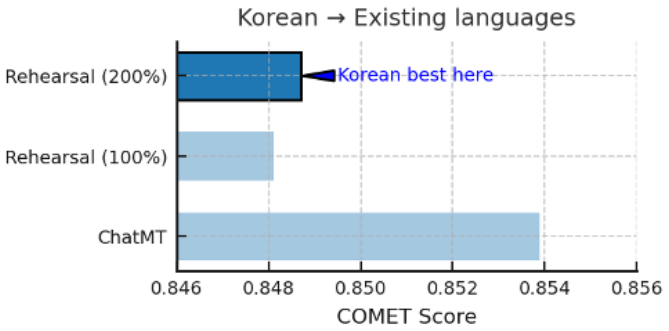

그림 2. 한국어 → 기존 언어 번역 성능

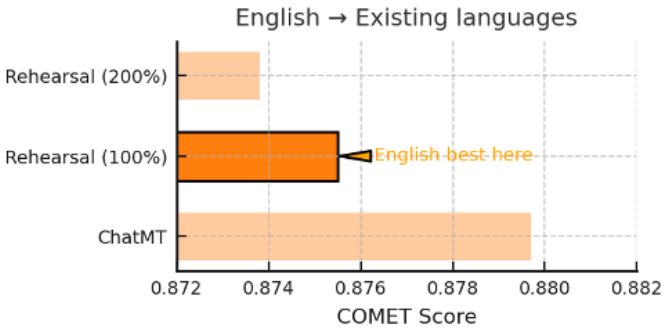

그림 3. 영어 → 기존 언어 번역 성능

4.2 모델 병합

리허설 기반 학습은 기존 언어 성능 보존에 효과적이었으나, 언어별로 최적의 데이터 비율은 서로 다르게 나타났다. 그림 2에서는 한국어 → 기존 언어 번역에서 리허설 200% 설정이 100% 설정보다 더 우수한 성능을 보임을 확인할 수 있으며, 그림 3에서는 영어 → 기존 언어 번역에서 리허설 100% 설정이 상대적으로 더 좋은 성능을 보임을 확인할 수 있다. 이는 리허설 데이터 비율이 언어별 학습 특성에 따라 다르게 작용함을 보여주며, 단일 비율로는 모든 언어에서 균일한 성능 최적화를 달성하기 어렵다는 한계를 시사한다. 이러한 차이는 리허설 데이터 샘플링 시 언어별 데이터 구성이 상이하기 때문에, 동일한 비율을 적용하더라도 실제 학습에 반영되는 데이터 분포가 달라져 성능 차이가 발생한 것으로 해석할 수 있다.

이러한 관찰을 바탕으로, 본 연구에서는 리허설 100%와 200% 모델을 병합하여 각 설정이 가지는 장점을 통합하고자 하였다. 모델 병합 과정에서는 DARE(Drop and Rescale)[10] 기법을 적용하였다. DARE는 학습된 파라미터 변화량 중 불필요한 부분을 확률적으로 제거하고, 남은 파라미터를 재조정하여 기대값을 유지하는 방식으로, 베이스 모델의 안정성을 보존하면서도 추가 학습된 모델의 정보를 효과적으로 흡수할 수 있도록 설계되었다. 이를 통해 개별 설정에서 나타난 언어별 성능 차이를 보완하고, 균형 잡힌 번역 성능 향상을 도모하였다.

5. 실험

5.1 실험 세팅

언어 확장 학습 및 모델 병합 기법의 효과를 검증하기 위해 다국어 번역 평가를 수행하였다. 실험은 Qwen2.5-1.5B 기반 ChatMT 모델을 바탕으로 진행하였으며, 평가에 사용된 데이터셋과 평가 지표는 다음과 같다.

5.1.1 테스트 데이터셋

번역 모델의 성능 평가는 일반 도메인과 게임 도메인 두 가지 환경에서 수행하였다. 일반 도메인 평가를 위해서는 공개 벤치마크인 Flores-200[4]을 사용하여 16개 언어쌍에 대한 번역 성능을 측정하였다. 또한 게임 도메인 내부적으로 구축된 게임 채팅 병렬 데이터셋을 활용하였다. 각 언어쌍은 1,000문장 규모로 구성되었다.

5.1.2 평가 지표

본 연구에서는 번역문과 참조문 간의 형태적 및 의미적 유사성을 다각도로 검증하기 위해 다음의 네 가지 지표를 사용하였다.

- **chrF**[12] 문자 n-그램 기반의 F-score로, 형태적 유사성을 정량적으로 평가한다.
- **COMET**[13] 사전학습된 신경망 기반 지표로, 의미적 적합성을 측정하는 번역 품질 평가 척도이다.
- **COMET-Kiwi**[14] 참조문 없이 번역의 유창성과 의미적 적합성을 직접 평가할 수 있는 지표이다.
- **mBERTScore**[15] 다국어 BERT 임베딩을 기반으로 한 의미적 유사도 지표로, 언어 간 의미 보존 여부를 평가한다.

5.2 실험 결과

실험 결과에서 Merged model은 두 가지 리허설 방법론과 기본 모델인 ChatMT를 결합한 모델이다. 점수는 한국어→16개 언어 번역 결과를 기준으로, 기존 언어와 신규 언어 각각에 대해 평균을 낸 값이다. 표에서는 가장 좋은 성능을 볼드체, 두 번째로 좋은 성능을 밑줄로 표시하였다.

5.2.1 일반 도메인 성능

일반 도메인에서의 성능 비교 결과는 표 1과 표 2에서 각각 확인할 수 있다. 기존 언어에 대한 번역 품질은 확장 전 모델인 ChatMT가 가장 좋은 성능을 보이지만, 다른 리허설 방법론만 적용한 두 개의 모델보다 Merged model이 ChatMT의 성능을 99.72% 유지하였다. 한편 신규 언어에 대해서는 Merged model이 ChatMT 대비 chrF 기준 약 7.7배, COMET 기준 38.6% 향상된 성능을 보였다.

[4] https://github.com/facebookresearch/flores/tree/main/flores200

표 1. 일반 도메인 번역 평가 (한국어 → 기존 언어)

Models	**chrF**	**COMET**	**COMET-Kiwi**	**BERTScore**
ChatMT (baseline)	**43.4302**	**0.8539**	**0.8097**	**0.8496**
Rehearsal (100%)	42.8311	0.8481	0.8010	0.8469
Rehearsal (200%)	42.8510	0.8487	0.8012	0.8473
Merged model	43.1814	0.8515	0.8048	0.8486

표 2. 일반 도메인 번역 평가 (한국어 → 신규 언어)

Models	**chrF**	**COMET**	**COMET-Kiwi**	**mBERTScore**
ChatMT (baseline)	6.1713	0.6025	0.7386	0.6995
Rehearsal (100%)	47.1234	0.8320	0.7484	0.8291
Rehearsal (200%)	47.0995	0.8320	0.7477	0.8294
Merged model	**47.4296**	**0.8351**	**0.7522**	**0.8304**

표 3. 게임 도메인 번역 평가 (한국어 → 기존 언어)

Models	**chrF**	**COMET**	**COMET-Kiwi**	**mBERTScore**
ChatMT (baseline)	51.6810	0.8320	**0.7331**	0.8506
Rehearsal (100%)	51.5780	0.8331	0.7294	0.8515
Rehearsal (200%)	51.8819	0.8329	0.7288	0.8523
Merged model	**52.2677**	**0.8364**	0.7313	**0.8534**

표 4. 게임 도메인 번역 평가 (한국어 → 신규 언어)

Models	**chrF**	**COMET**	**COMET-Kiwi**	**mBERTScore**
ChatMT (baseline)	4.5828	0.6406	0.6745	0.7015
Rehearsal (100%)	54.2095	0.8368	0.6884	0.8623
Rehearsal (200%)	54.3023	0.8361	0.6883	0.8624
Merged model	**54.5494**	**0.8392**	**0.6906**	**0.8637**

표 5. 언어 확장 전후 번역 예시

Source: 일부 축제들은 어린아이들이 있는 가족들을 위한 특별한 캠핑 공간을 가지고 있습니다.		
Target Language	**ChatMT**	**Merged model**
Malay	一些節慶有特別的露營區,適合有小孩的家庭	Beberapa festival mempunyai ruang perkemahan khas untuk keluarga yang mempunyai kanak-kanak.
Indonesian	有些節日有有小孩的家庭準備的特別露營區	Beberapa festival memiliki tempat berkemah khusus untuk keluarga yang memiliki anak kecil.

5.2.2 게임 도메인 성능

게임 도메인 평가에서의 성능 비교 결과는 표 3과 표 4에서 확인 가능하다. 기존 언어에 대한 성능의 경우, 일반 도메인과 상이하게 chrF, COMET, mBERTScore이 ChatMT를 능가하는 성능을 보였다. 신규 언어에 대해서는 일반 도메인과 유사하게 Merged model이 CHRF 기준 약 10배 향상, COMET 기준 31% 향상하며 그외 모든 지표에서 큰 폭의 성능 향상을 보였다.

5.2.3 번역 모델 생성 예시

실제 언어 확장 모델의 생성 예시는 표 5에서 확인할 수 있다. 한국어 소스 문장을 입력했을 때, 기존 ChatMT는 새로운 언어에 대해 학습되지 않아 타깃 언어가 아닌 다른 언어로 출력을 생성하였다. 반면, 언어 확장을 적용한 Merged model은 타깃 언어와 일치하는 언어로 정확한 번역을 생성하였다.

결과적으로, Merged model은 ChatMT의 기존 언어 성능을 유지하면서도 두 가지 확장 모델의 장점을 결합하여 신규 언어에서도 강건한 성능을 보임을 확인하였다.

6. 결론

본 연구는 다국어 번역 모델의 언어 확장 과정에서 발생하는 치명적 망각 문제를 완화하기 위해 리허설 학습과 모델 병합 기법을 실험적으로 적용하였다. Qwen2.5 기반 1.5B 모델을 10개에서 16개 언어로 확장한 결과, Merged model은 기존 언어 성능을 COMET 기준 99.7% 유지하면서도 신규 언어에서 chrF 기준 7.7–10배, COMET 기준 31–38% 향상을 달성하였다. 특히 게임 도메인에서는 기존 언어에서도 베이스라인을 초과하는 성능을 보여 제안 접근법의 일반화 가능성을 확인하였다. 본 연구의 결과는 본래 모델 구조를 변경하거나 복잡한 방법론 없이도 기존 언어 성능을 보존하면서 새로운 언어를 효과적으로 확장할 수 있음을 보여주었으며, 이는 실제 서비스 환경에서 효율적이고 실용적인 다국어 번역 모델 확장 전략을 제공한다는 점에서 의의가 있다.

감사의 글

This work was supported by the Institute of Information & Communications Technology Planning & Evaluation (IITP) grant funded by the Korea government (MSIT) [RS-2021-II211341, Artificial Intelligent Graduate School Program (Chung-Ang University)] and by the National Research Foundation of Korea (NRF) grant funded by the Korea government (MSIT) (RS-2025-00556246).

참고문헌

[1] M. Cui, P. Gao, W. Liu, J. Luan, and B. Wang, "Multilingual machine translation with open large language models at practical scale: An empirical study," *in Proceedings of the 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics (NAACL 2025)*, pp. 5420–5443, 2025.

[2] W. Zhu, H. Liu, Q. Dong, J. Xu, S. Huang, L. Kong, J. Chen, and L. Li, "Multilingual machine translation with large language models: Empirical results and analysis," *in Findings of the Association for Computational Linguistics (NAACL 2024)*, pp. 2765–2781, 2024.

[3] H. Zhou, Z. Wang, S. Huang, X. Huang, X. Han, J. Feng, C. Deng, W. Luo, and J. Chen, "Moe-lpr: Multilingual extension of large language models through mixture-of-experts with language priors routing," *in Proceedings of the Thirty-Ninth AAAI Conference on Artificial Intelligence (AAAI 2025)*, pp. 26 092–26 100, 2025.

[4] J. Liu, K. Huang, H. Yu, J. Li, J. Su, and D. Huang, "Continual learning for multilingual neural machine translation via dual importance-based model division," *in Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (EMNLP 2023)*, pp. 12 011–12 027, 2023.

[5] X. Zhang, Y. Liang, F. Meng, S. Zhang, Y. Chen, J. Xu, and J. Zhou, "Less, but better: Efficient multilingual expansion for llms via layer-wise mixture-of-experts," *in Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (ACL 2025)*, pp. 17 948–17 963, 2025.

[6] T. Blevins, T. Limisiewicz, S. Gururangan, M. Li, H. Gonen, N. A. Smith, and L. Zettlemoyer, "Breaking the curse of multilinguality with cross-lingual expert language models," *in Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing (EMNLP 2024)*, pp. 10 822–10 837, 2024.

[7] J. Wu, Y. Liu, and C. Zong, "F-malloc: Feed-forward memory allocation for continual learning in neural machine translation," *in Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL 2024)*, pp. 7180–7192, 2024.

[8] Y. Sheng, S. Cao, D. Li, C. Hooper, N. Lee, S. Yang, C. Chou, B. Zhu, L. Zheng, K. Keutzer, J. E. Gonzalez, and I. Stoica, "Slora: Scalable serving of thousands of lora adapters," *in Proceedings of Machine Learning and Systems 6 (MLSys 2024)*, 2024.

[9] S.-A. Rebuffi, A. Kolesnikov, G. Sperl, and C. H. Lampert, "icarl: Incremental classifier and representation learning," *in Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR 2017)*, pp. 2001–2010, 2017.

[10] L. Yu, B. Yu, H. Yu, F. Huang, and Y. Li, "Language models are super mario: Absorbing abilities from homologous models as a free lunch," *in Proceedings of the 41st International Conference on Machine Learning (ICML 2024)*, 2024.

[11] Z. Man, K. Huang, Y. Zhang, Y. Chen, Y. Chen, and J. Xu, "ICL: Iterative continual learning for multi-domain neural machine translation," *in Findings of the Association for Computational Linguistics (EMNLP 2024)*, Y. Al-Onaizan, M. Bansal, and Y.-N. Chen, Eds., pp. 7732–7743, 2024.

[12] M. Popović, "chrf: character n-gram f-score for automatic mt evaluation," *in Proceedings of the Tenth Workshop on Statistical Machine Translation (WMT 2015)*, pp. 392–395, 2015.

[13] R. Rei, C. Stewart, A. C. Farinha, and A. Lavie, "COMET: A neural framework for MT evaluation," *in Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP 2020)*, pp. 2685–2702, 2020.

[14] R. Rei, M. Treviso, N. M. Guerreiro, C. Zerva, A. C. Farinha, C. Maroti, J. G. C. de Souza, T. Glushkova, D. Alves, L. Coheur, A. Lavie, and A. F. T. Martins, "Cometkiwi: Ist-unbabel 2022 submission for the quality estimation shared task," *in Proceedings of the Seventh Conference on Machine Translation (WMT 2022)*, pp. 634–645, Dec. 2022.

[15] T. Zhang, V. Kishore, F. Wu, K. Q. Weinberger, and Y. Artzi, "Bertscore: Evaluating text generation with BERT," *in Proceedings of the 8th International Conference on Learning Representations (ICLR 202)*, 2020.