지시 학습에 기반한 검색 증강 언어 모델

장진희°[1], 이정[2], 서대룡[3], 전동현[4], 강인호[5], 나승훈*[6]
전북대학교[1,2,*6], 네이버[3,4,5]
{zhenxi, fhqlatm, nash}@jbnu.ac.kr, {daeryong.seo, donghyeon.jeon, once.ihkang}@navercorp.com

Retrieval-Augmented Language Model based on Instruction Tuning

Jinhee Jang°[1], Joung Lee[2], Daeryong Seo[3], Donghyeon Jeon[4], Inho Kang[5], Seung-Hoon Na*[6]
Jeonbuk National University[1,2,*6], NAVER Corporation[3,4,5]

요 약

대규모 언어 모델(Large Language Model)은 구축된 시점의 코퍼스에 의존적인 한계로 최신 정보를 반영하기 어렵다는 단점이 존재한다. 이에 주어진 질의와 연관된 문서들을 검색하여 생성 능력을 강화하는 검색 증강 언어 모델(Retrieval-Augmented Language Model)에 대한 연구가 활발히 진행되고 있다. 본 연구에서는 한국어 언어 모델의 검색 증강 성능을 개선하기 위해 검색된 문서들에 대해 관련 여부를 모델이 판단하고 이에 기반한 응답을 적절히 생성할 수 있도록 지시 학습을 수행한다. 특히 오픈 도메인 질의 응답(Open-Domain Question Answering) 과업에서 F1-1.9, EM-2.6 향상된 성능을 보여 지시 학습을 통해 검색 증강 언어 모델의 생성 성능을 개선할 수 있다는 사실을 입증하였다.

1. 서 론

자연언어처리 분야의 비약적인 성장과 더불어 대규모 언어 모델(Large Language Model, LLM)의 발전으로 다양한 태스크에서 주목할 만한 성능을 보이고 있다 [1, 2]. 특히 최근에는 대규모 언어 모델이 학습하지 못한 과업에서 우수한 생성 능력을 보이는 지시 학습(Instruction Tuning)과 관련된 연구가 활발히 수행되고 있다 [3].

다양한 벤치마크에서 입증된 성능에도 불구하고 언어 모델은 필연적으로 최신 정보가 반영된 답변을 생성하기 어렵다는 단점이 있다 [4, 5]. 하지만 사전 학습된 언어 모델에 새로운 지식을 주입하기 위해 모델을 다시 훈련하는 것은 막대한 양의 시간과 비용을 필요로 한다.

이러한 문제를 해소하고 모델의 생성 능력을 강화하기 위해 검색 증강 언어 모델(Retrieval-Augmented Language Model, RALM)과 관련된 연구가 지속적으로 수행되어왔다 [6]. 하지만 검색 증강 언어 모델 또한 검색 데이터의 품질을 검증하고 관련된 정보를 구별하여 정확한 응답을 생성하는 것이 주요 과제로 남아 있다. 이에 따라 본 연구에서는 지시 학습을 통해 개선된 한국어 검색 증강 언어 모델을 구축하고 오픈 도메인 질의 응답(Open-Domain Question Answering) 과업에 효과적으로 적용하여 성능을 입증한다.

2. 관련 연구

2.1 지시 학습

사전 학습된 대규모 언어 모델을 주어진 모든 과업에 대해 Fine-tuning (미세 조정) 하기에는 막대한 시간과 비용이 소모된다는 한계가 존재한다. 이에 따라 FLAN[7]은 언어 모델이 학습하지 못한 데이터셋이나 과업이 주어졌을 때 zero-shot 환경에서도 우수한 성능을 내도록 다양한 지시문을 통해 모델을 학습하는 방법을 제안한다. 또한 Self-instruct[8]는 지시 학습을 위한 데이터를 반복적으로 증강하고 이를 통해 학습된 모델이 다양한 과업에서 개선된 성능을 보임을 입증하였다.

2.2 검색 증강 언어 모델

검색 증강 언어 모델은 일반적으로 입력과 연관된 문서를 검색하고 검색된 문서에 기반하여 적절한 응답을 생성하도록 학습된다. 대표적으로 kNN-LM[9] 및 RETRO[10]는 토큰 생성 과정에서 각 토큰별 생성 확률을 보정하는 방식으로 검색 결과를 활용한다. 또한 In-context RALM[11]은 오픈 도메인 질의 응답 과업에서 주어진 쿼리에 대해 검색을 수행하고 기존 쿼리를 확장함으로써 모델이 외부 지식을 활용하는 간단한 검색 증강 프레임워크를 제안한다.

SAIL[12]은 상용 검색 모듈의 한계를 지적하고 대규모 언어 모델을 Fine-tuning하는 과정에서 사전 구축된 지시 학습 데이터셋을 통해 검색된 결과에서 부정확하거나 관련 없는 문서를 제외하여 답안을 생성하도록 모델을 학습한다. 본 연구에서는 한국어 질의 응답 데이터셋을 기반으로 지시 학습 데이터셋을 구축하고 이를 한국어에 효과적으로 적용하여 향상된 검색 증강 언어 모델의 성능을 보인다.

3. 제안 방법

3.1 지시 학습에 기반한 검색 증강 언어 모델

본 연구에서 제안하는 지시 학습 기반 검색 증강 언어 모델의 전체적인 구조는 그림 1과 같다.

지시문 및 질의와 함께 해당 질의에 대한 Top-k 개의 검색 결과

*) 교신저자 (Corresponding author)

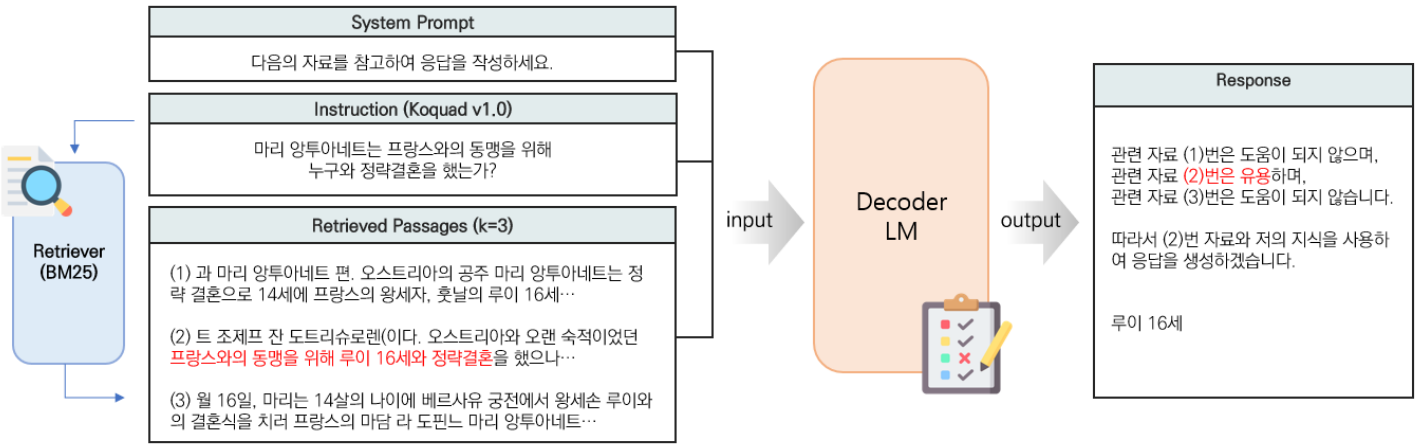

그림 1: 지시 학습에 기반한 검색 증강 언어 모델의 학습 과정

가 모델에 입력되면 어떤 passage가 유용한지 판단할 수 있도록 학습된다. 이후 언어 모델은 제공된 연관 passage와 매개변수에 내재한 지식을 활용하여 질의에 대한 적절한 응답을 생성한다.

3.2 데이터셋 구축

본 실험에서는 한국어 위키피디아 덤프[1] 및 KorQuAD 1.0 데이터셋[2]을 기반으로 지시문을 포함한 질의 응답 데이터셋을 구축하였다. 또한 검색기로는 pyserni[3]의 BM25 검색 모듈을 활용하였다. 해당 검색기의 Accuracy는 k가 3일 때 0.57로 이는 검색 결과에 유용한 passage가 1개 이상 포함될 확률을 나타낸다.

먼저 한국어 위키피디아 전체 문서 집합을 각 60개의 토큰으로 이루어진 chunked passage로 분할하여 검색 코퍼스 C를 구축한다. 이후 BM25 검색 모듈을 활용하여 KorQuAD 데이터셋 내의 질의 응답 쌍 $\{q_i, a_i\}_{i=1}^{|Q|}$에서 각 q마다 상위 k개의 연관된 chunked passages $P = \{p_1, p_2, \cdots, p_k\}$를 검색한다. 최종적으로 검색 대상인 chunked passage p_i에 *answer span*이 포함된 경우 정답과 관련 있는 passage로 판단하여 그림 1의 Response와 같이 모델이 검색된 문서 p_i의 검색 Index를 연관 passage로 분류하도록 label을 구성하였다.

위 과정을 거쳐 총 50,844건의 KorQuAD 1.0 질의 응답 쌍으로부터 학습 데이터셋 49,844건과 검증 데이터셋 1,000건을 구축하였다.

4. 실험

4.1 실험 설계

학습을 위해 EleutherAI의 오픈 소스 한국어 언어 모델인 Polyglot-Ko[13]를 사용한다. Polyglot-Ko 모델은 1.2TB의 한국어 데이터를 기반으로 GPT-NeoX를 학습시킨 대표적인 한국어 대규모 언어 모델 중 하나이다. 본 연구에서는 Polyglot-Ko-1.3B 모델로 실험을 수행하였으며, 학습 시 Optimizer는 AdamW, Training epoch은 10, Batch size는 1,024, 그리고 Learning rate는 7e-5로 설정하였다.

4.2 실험 결과

표 1에서 검색된 passage의 갯수인 k가 3일 때의 오픈 도메인 질의 응답 성능을 확인 할 수 있다. base 모델(RALM$_{ft}$)은 In-context RALM [11]의 구조를 직접 설계하여 Fine-tuning한 결과로, P와 q를 연결(concatenate)하여 언어 모델이 질의에 따른 적절한 응답을 생성하도록 학습되었다. 실험 결과 모든 평가 지표에서 지시 학습을 수행한 모델이 기존의 RALM 방식 대비 개선된 성능을 보였다. 특히 F1-1.39, EM-2.6 향상되어 한국어 오픈 도메인 질의 응답 과업에서 지시 학습을 통한 성능 개선이 가능함을 입증하였다.

	F1	EM	SacreBLEU	Meteor	RougeL
RALM$_{ft}$ (base)	48.38	43.40	35.38	0.3044	0.1589
ours	**49.77**	**46.00**	**47.77**	**0.3174**	**0.1595**

표 1: 오픈 도메인 질의 응답 성능 ($k = 3$)

그림 2는 검색된 passage 수에 따른 ($k = \{1, 3, 5, 10\}$) 언어 모델의 F1 및 EM 성능을 나타낸 그래프이다. 검색된 passage가 3개인 경우 가장 높은 성능을 기록하였으며, 이후 검색된 passage가 증가할수록 성능이 점차 감소하였다. 특히 검색된 passage가 10개일 때 F1 및 EM 성능이 모두 15%p 이상 하락하였다. 이를 통해 제안된 방법을 통해 학습된 언어 모델이 일정 개수 이상의 passage가 입력되면 관련 passage를 판별하는데 어려움을 겪는 것으로 파악된다.

1) https://dumps.wikimedia.org/kowiki/
2) https://korquad.github.io/
3) https://github.com/castorini/pyserini

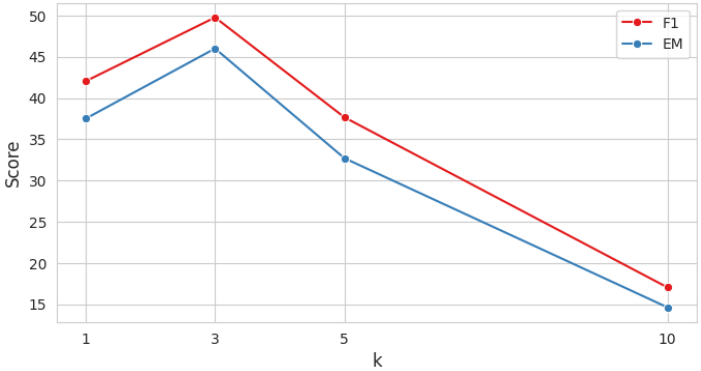

그림 2: 검색 문서 수에 따른 F1, EM 성능

5. 결론

본 연구는 지시 학습을 수행하여 기존 검색 증강 언어 모델의 생성 능력을 개선하고 오픈 도메인 질의 응답 과업에서의 향상된 성능을 입증한다. 특히 기존 방식과는 달리 언어 모델이 검색된 k개의 passage에서 연관된 passage를 판단하고 적절한 응답을 생성하여 F1과 EM에서 의미있는 성능 개선을 이루었음을 확인하였다.

다만 검색 증강 언어 모델의 성능은 비단 언어 모델의 성능만이 아니라 관련된 passage를 탐색하는 검색 모듈 역시 큰 영향을 미친다. 따라서 향후 연구에서는 Dense Retrieval 검색 방식을 적용하여 보다 정확한 검색 결과와 함께 검색 증강 언어 모델의 성능을 향상 시킬 계획이다.

참고 문헌

[1] T. Brown, B. Mann, N. Ryder, M. Subbiah, J. D. Kaplan, P. Dhariwal, A. Neelakantan, P. Shyam, G. Sastry, A. Askell, *et al.*, "Language models are few-shot learners," *Advances in neural information processing systems*, vol. 33, pp. 1877–1901, 2020.

[2] B. Kim, H. Kim, S.-W. Lee, G. Lee, D. Kwak, D. H. Jeon, S. Park, S. Kim, S. Kim, D. Seo, *et al.*, "What changes can large-scale language models bring? intensive study on hyperclova: Billions-scale korean generative pretrained transformers," *arXiv preprint arXiv:2109.04650*, 2021.

[3] S. Zhang, L. Dong, X. Li, S. Zhang, X. Sun, S. Wang, J. Li, R. Hu, T. Zhang, F. Wu, *et al.*, "Instruction tuning for large language models: A survey," *arXiv preprint arXiv:2308.10792*, 2023.

[4] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Küttler, M. Lewis, W.-t. Yih, T. Rocktäschel, *et al.*, "Retrieval-augmented generation for knowledge-intensive nlp tasks," *Advances in Neural Information Processing Systems*, vol. 33, pp. 9459–9474, 2020.

[5] K. Guu, K. Lee, Z. Tung, P. Pasupat, and M. Chang, "Retrieval augmented language model pre-training," in *International conference on machine learning*, pp. 3929–3938, PMLR, 2020.

[6] H. Li, Y. Su, D. Cai, Y. Wang, and L. Liu, "A survey on retrieval-augmented text generation," *arXiv preprint arXiv:2202.01110*, 2022.

[7] J. Wei, M. Bosma, V. Y. Zhao, K. Guu, A. W. Yu, B. Lester, N. Du, A. M. Dai, and Q. V. Le, "Finetuned language models are zero-shot learners," *arXiv preprint arXiv:2109.01652*, 2021.

[8] Y. Wang, Y. Kordi, S. Mishra, A. Liu, N. A. Smith, D. Khashabi, and H. Hajishirzi, "Self-instruct: Aligning language model with self generated instructions," *arXiv preprint arXiv:2212.10560*, 2022.

[9] U. Khandelwal, O. Levy, D. Jurafsky, L. Zettlemoyer, and M. Lewis, "Generalization through memorization: Nearest neighbor language models," *arXiv preprint arXiv:1911.00172*, 2019.

[10] S. Borgeaud, A. Mensch, J. Hoffmann, T. Cai, E. Rutherford, K. Millican, G. B. Van Den Driessche, J.-B. Lespiau, B. Damoc, A. Clark, *et al.*, "Improving language models by retrieving from trillions of tokens," in *International conference on machine learning*, pp. 2206–2240, PMLR, 2022.

[11] O. Ram, Y. Levine, I. Dalmedigos, D. Muhlgay, A. Shashua, K. Leyton-Brown, and Y. Shoham, "In-context retrieval-augmented language models," *arXiv preprint arXiv:2302.00083*, 2023.

[12] H. Luo, Y.-S. Chuang, Y. Gong, T. Zhang, Y. Kim, X. Wu, D. Fox, H. Meng, and J. Glass, "Sail: Search-augmented instruction learning," *arXiv preprint arXiv:2305.15225*, 2023.

[13] H. Ko, K. Yang, M. Ryu, T. Choi, S. Yang, J. Hyun, S. Park, and K. Park, "A technical report for polyglot-ko: Open-source large-scale korean language models," 2023.